



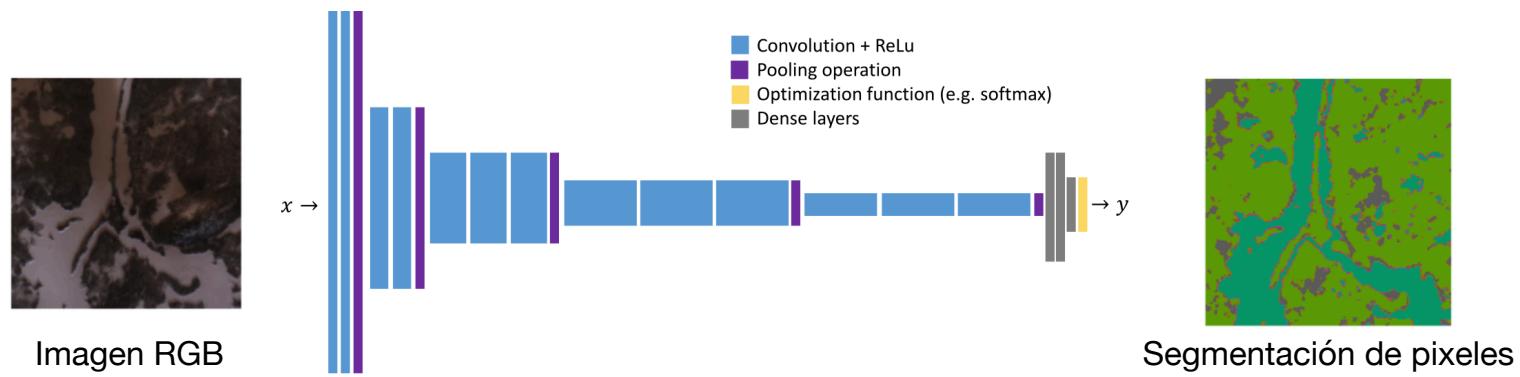
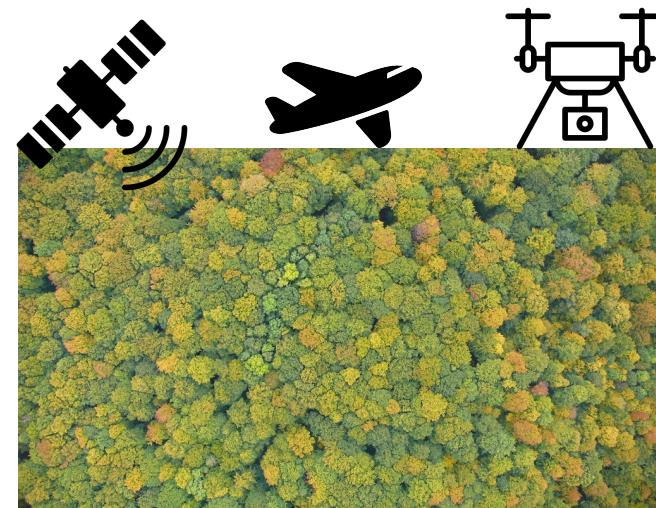
# **¿Pueden los modelos basados en arquitecturas de deep learning aplicarse en nuevas regiones geográficas?: una perspectiva desde teledetección**

**María Alejandra Bravo**

**PhD (c) en Data Science, Universidad Adolfo Ibáñez**

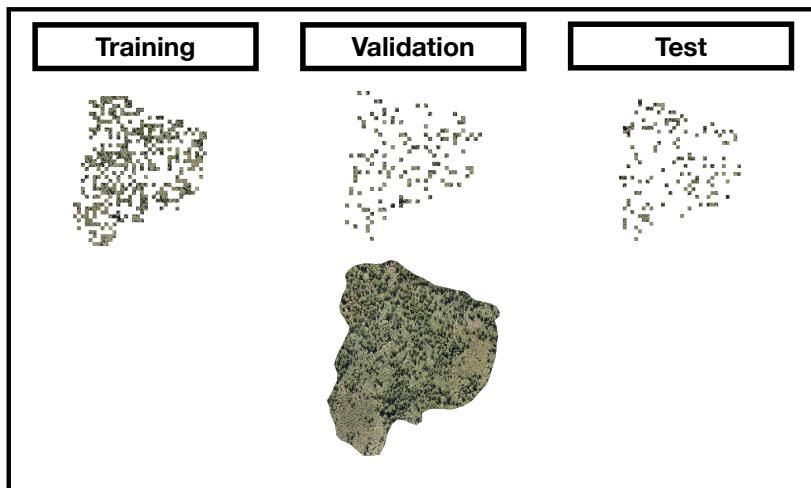
# Remote Sensing y Detección de Objetos

- Es posible **observar la tierra** utilizando diferentes técnicas de remote sensing, como **satélites y drones**.
- Imágenes RGB, multiespectrales e hiperespectrales.
- Las **redes neuronales convolucionales** (CNN) son útiles para detectar vegetación.

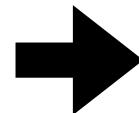


# Problema

En Remote Sensing es usual **transferir el modelo** a nuevas adquisiciones de datos



**El modelo utilizado en nuevas  
adquisiciones de datos**

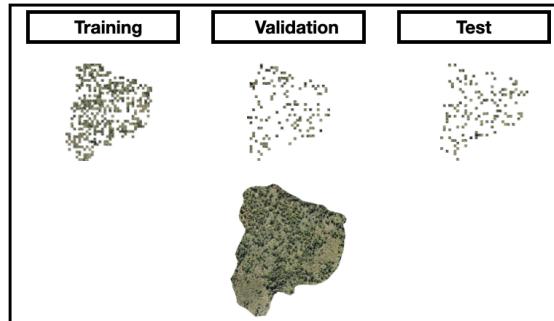


Los datos de Remote Sensing pueden **presentar características únicas** en  
cada adquisición de datos

# Research Gap

Es necesario **evaluaciones que consideren transferir los modelos** a nuevos area o adquisiciones no consideradas durante el entrenamiento

La evaluación del modelo puede ser demasiado optimista.



El modelo puede colapsar

?

¿Puede el modelo ser utilizado  
en nuevos datos?

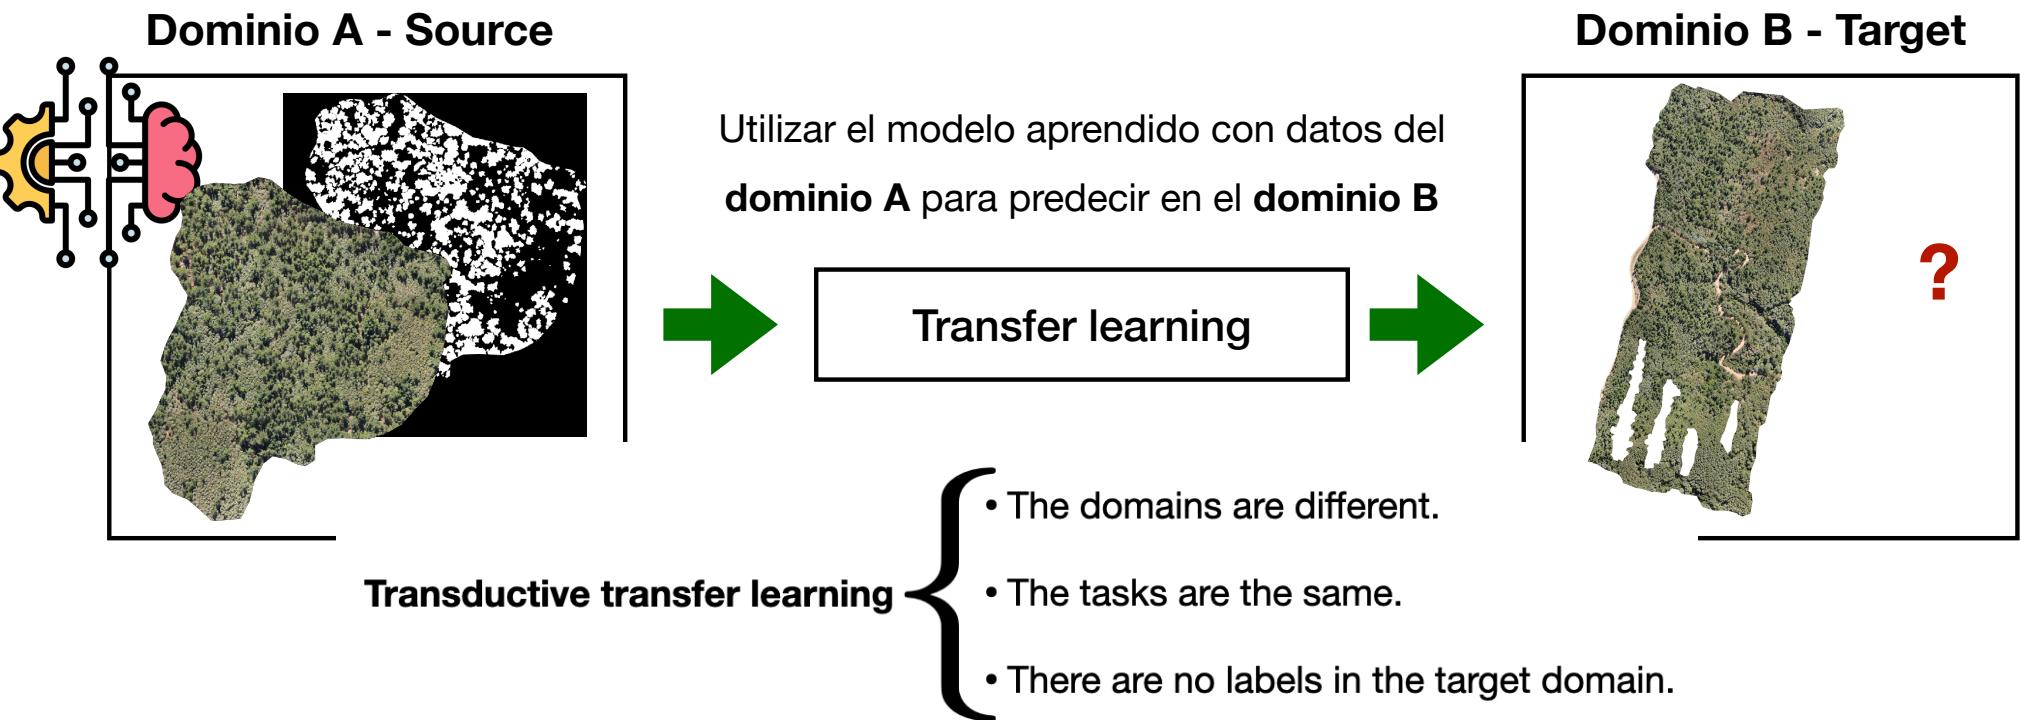


Cuando un modelo se aplica a nuevos datos, las **predicciones/estimaciones pueden ser inciertas**.

Por lo tanto, la **cuantificación de la similitud** podría contribuir a evaluar las posibilidades de una **transferencia exitosa**, facilitando la aplicación práctica de los modelos.

# Transfer learning

El transfer learning es un paradigma que utiliza el **conocimiento de un dominio de origen** para beneficiar a un dominio objetivo relacionado

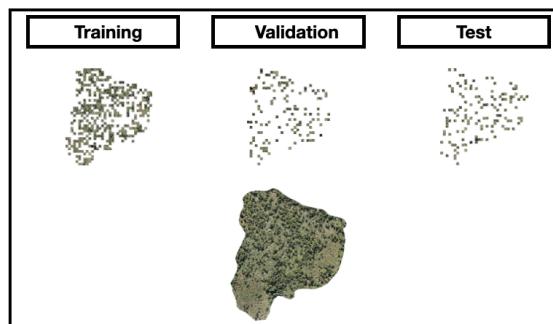


# Objetivo específico 1

## Primera propuesta

Evaluar el desempeño del transfer learning en modelos CNN cuando se aplican a nuevos dominios no considerados durante el proceso de entrenamiento, comparando el entrenamiento con datos homogéneos y heterogéneos.

La evaluación del modelo puede ser demasiado optimista.

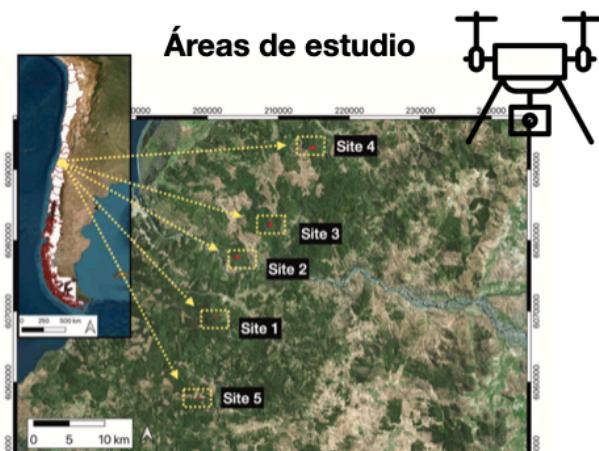


El modelo puede colapsar



# Metodología: Objetivo específico 1

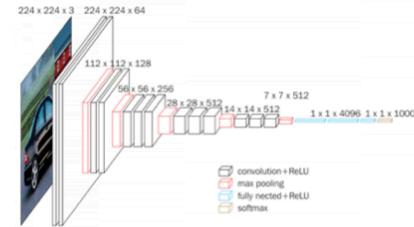
Evaluar el desempeño del transfer learning en modelos CNN cuando se aplican a nuevos dominios no considerados durante el proceso de entrenamiento, comparando el entrenamiento con datos homogéneos y heterogéneos.



Cobertura de invasiones de *P. radiata*

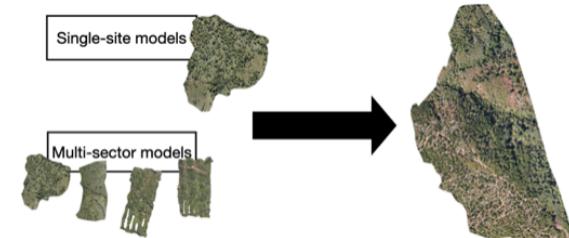
## Entrenamiento de modelos de regresión basados en CNN

Entrenamiento basado en arquitecturas pre-entrenadas y búsqueda de hiperparámetros



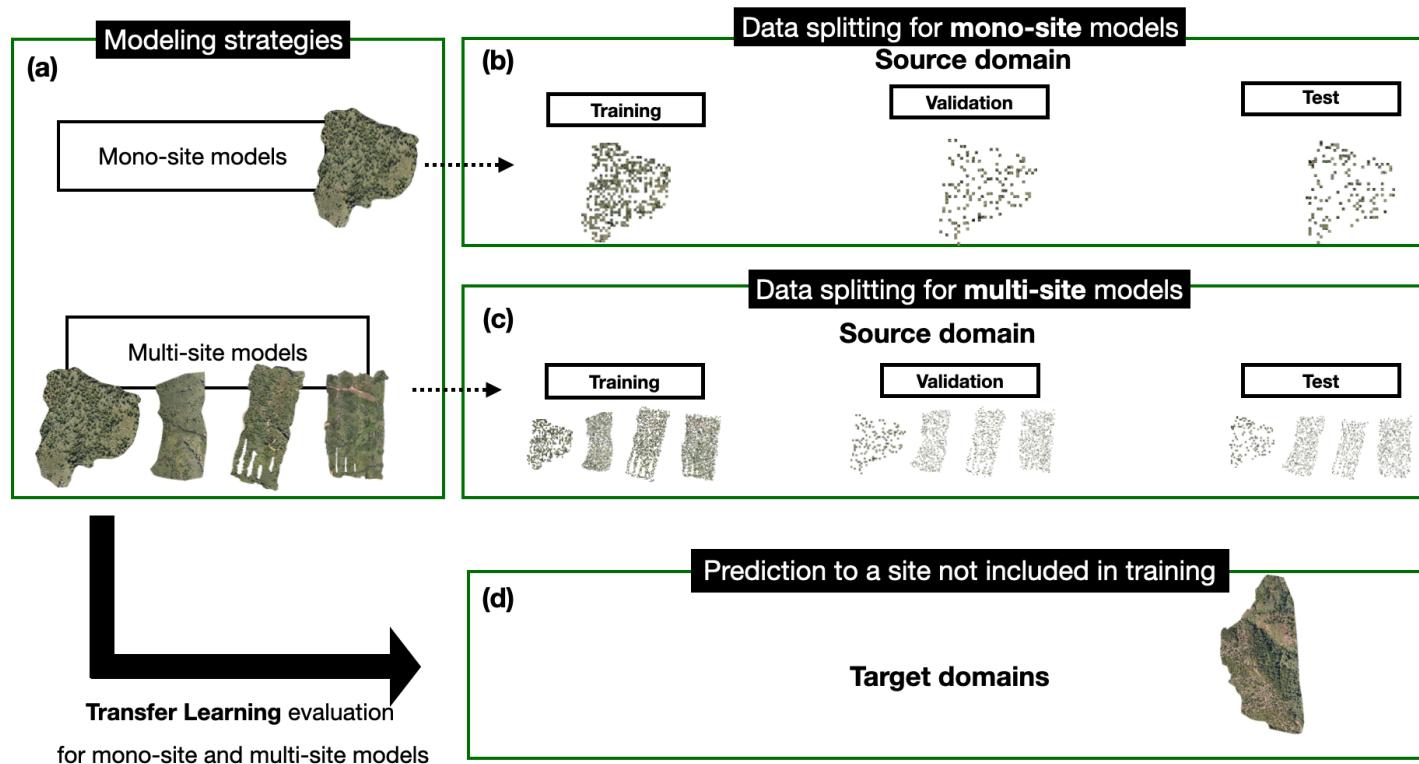
## Evaluación de transfer learning en modelos mono-sitio y multi-sitio

Predicciones en sitios no utilizados en el entrenamiento



# Metodología: Objetivo específico 1

Evaluar el desempeño del transfer learning en modelos CNN cuando se aplican a nuevos dominios no considerados durante el proceso de entrenamiento, comparando el entrenamiento con datos homogéneos y heterogéneos.



# Resultados: Objetivos específico 1

## Comparación del transfer learning en modelos mono-site y multi-site

		Site 1	Site 2	Site 3	Site 4	Site 5	$R^2$
mono-site	Test	0.871	0.916	0.930	0.950	0.891	
	Transfer learning	0.429	-1.770	0.622	0.027	-0.262	
multi-site	Test	0.798	0.889	0.888	0.939	0.918	
	Transfer learning	0.631	0.776	0.848	0.598	0.871	

- Las **evaluaciones en sitios independientes**, son **necesarias** para evitar una evaluación demasiado optimista del modelo.
- Los **modelos mono-sitio** muestran una **amplia variabilidad** en el desempeño.
- Los modelos **multi-site tiene mejor desempeño** en nuevos sitios.

# Resultados: Objetivo específico 1

Evaluar el desempeño del transfer learning en modelos CNN cuando se aplican a nuevos dominios no considerados durante el proceso de entrenamiento, comparando el entrenamiento con datos homogéneos y heterogéneos.

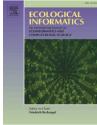
Ecological Informatics 82 (2024) 102684



Contents lists available at ScienceDirect

Ecological Informatics

journal homepage: [www.elsevier.com/locate/ecolinf](http://www.elsevier.com/locate/ecolinf)



Evaluating the ability of convolutional neural networks for transfer learning in *Pinus radiata* cover predictions

A. Bravo-Díaz<sup>a,\*</sup>, S. Moreno<sup>a</sup>, J. Lopatin<sup>a,b,c</sup>

<sup>a</sup> Universidad Adolfo Ibáñez, Diagonal Las Torres 2640, Santiago 7941169, Chile

<sup>b</sup> Data Observatory Foundation, ANID Technology Center No. D0210001, Santiago 7510277, Chile

<sup>c</sup> Center for Climate Resilience Research (CR2), University of Chile, Santiago 8370449, Chile

Neural Computing and Applications

ORIGINAL ARTICLE

## Convolutional neural network models with low spatial variability hamper the transfer learning process

Alejandra Bravo-Díaz<sup>1</sup>  · Sebastián Moreno<sup>1</sup> · Javier Lopatin<sup>1,2,3</sup>

Received: 19 December 2024 / Accepted: 1 April 2025

© The Author(s), under exclusive licence to Springer-Verlag London Ltd., part of Springer Nature 2025



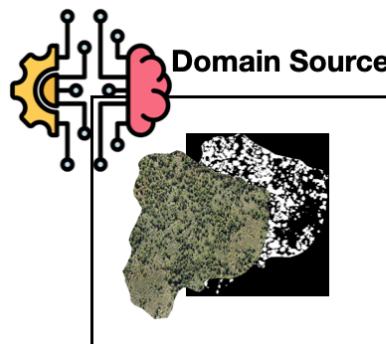
10



# Objetivo específico 2

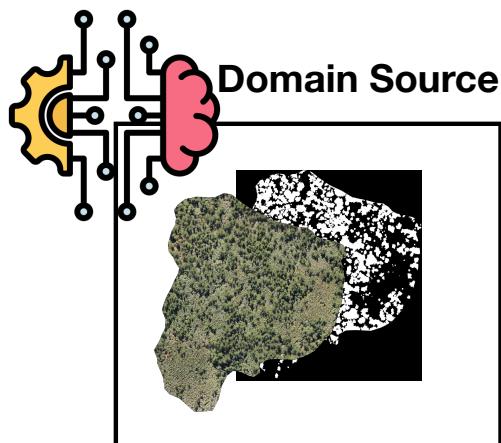
## Segunda propuesta

- Desarrollar un enfoque flexible para **cuantificar la similitud entre los dominios de source y target** con el fin de mejorar el desempeño del transfer learning



# Similitud en machine learning

- La similitud es una medida que cuantifica el **grado de semejanza** entre dos objetos, permitiendo evaluar relaciones entre conjuntos de datos, vectores, funciones u otras entidades matemáticas.
- Cuantificar esta similitud es fundamental para determinar la **correspondencia entre los dos dominios** y **minimizar el riesgo de transferencia negativa**.



?

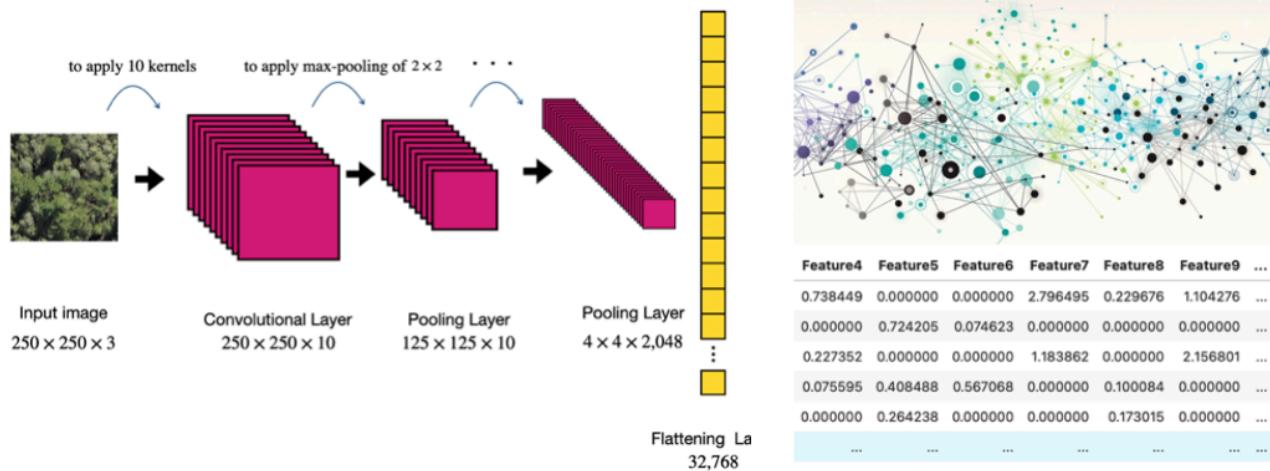
**Similarity between the  
Source and Target  
domains**



# Metodología: Objetivo específico 2

Desarrollar un enfoque flexible para cuantificar la similitud entre los dominios de source y target con el fin de mejorar el desempeño del transfer learning

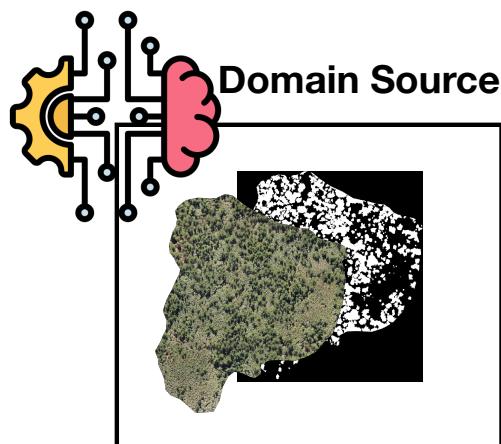
## Representations



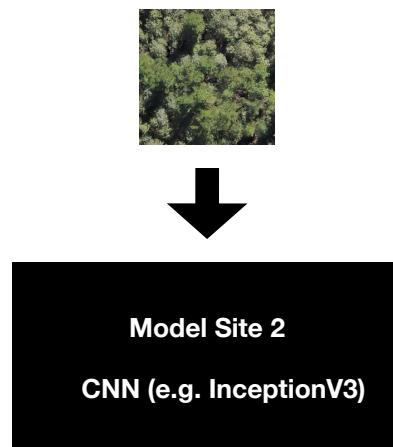
La similitud se puede cuantificar a nivel de  
representación

# Metodología: Objetivo específico 2

## Relación entre el error del modelo y el ruido gaussiano



Cobertura de invasiones de *P. radiata*



(1, 2048)

Agregamos ruido Gaussiano

Noise gaussian -> std [0.01, 0.1, 1, 2, 3, 4]

Se experimento con diferente porcentaje de elementos afectados por el noise

[10 %, 20 %, 30 %, 40 %, 50 %, 60 %, 70 %, 80 %, 90 %, 100 %]

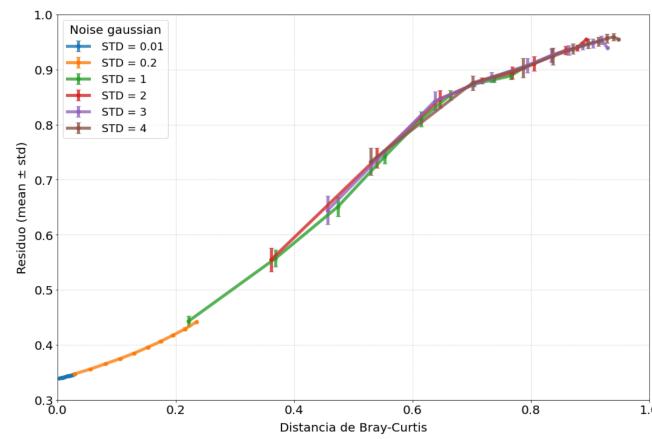
Por cada transformación al vector se busco relacionar el error del modelo y la distancia (medida de similitud).

Las transformaciones del vector en relación a noise y variación de % de elemento transformados se repitió 100 veces.

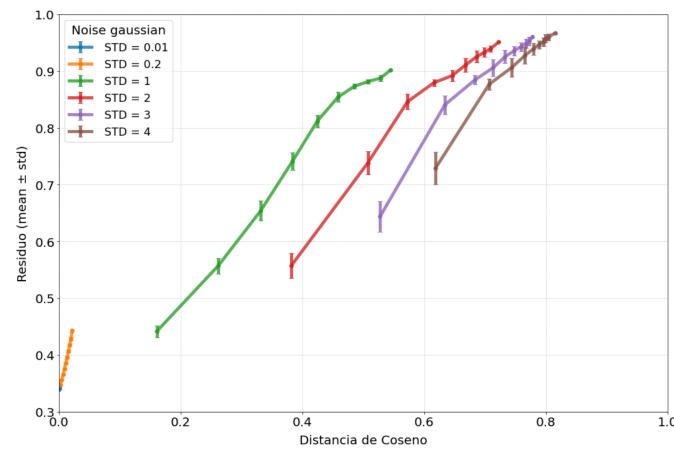
# Resultados: Objetivo específico 2

## Relación entre el error del modelo y el ruido gaussiano

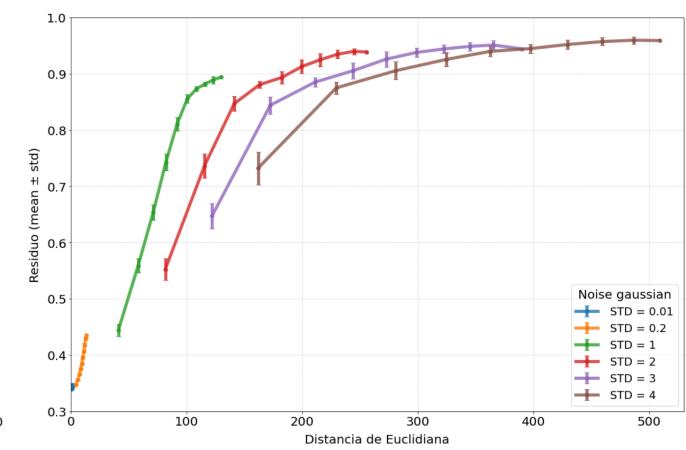
Distancia de Bray-curtis



Distancia de Coseno



Distancia de Euclidiana



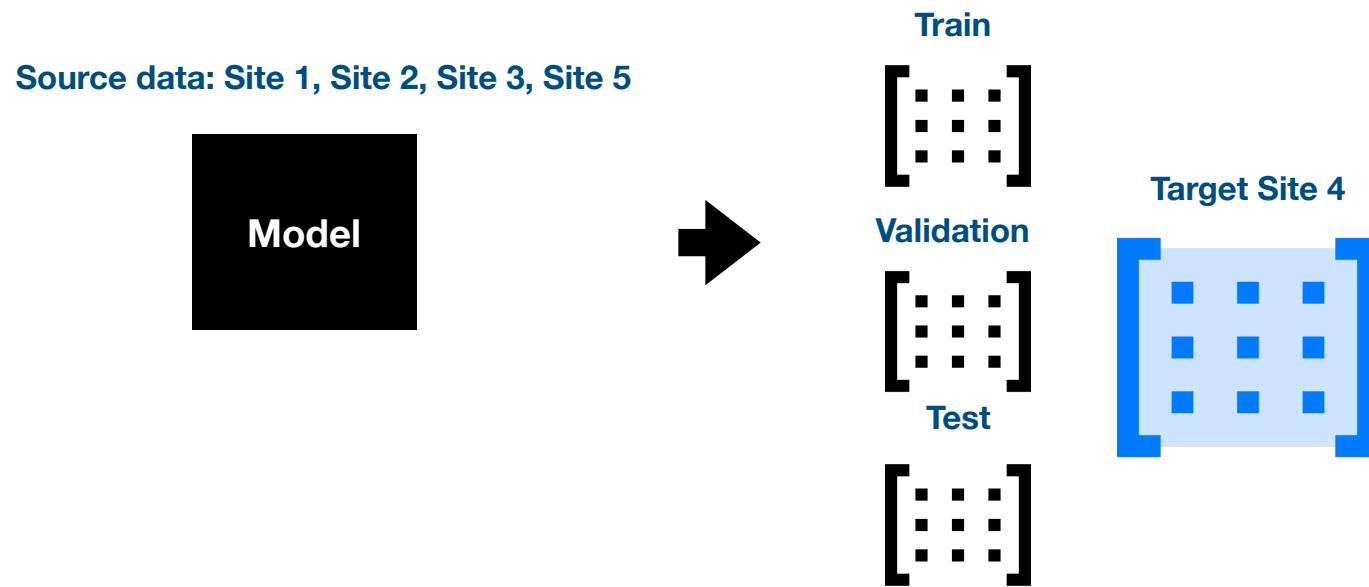
Los resultados sugieren que **Bray-Curtis** proporciona una estimación más precisa al relacionar el error del modelo con las similitudes entre vectores.

Esta métrica resulta especialmente adecuada para **vectores dominados por ceros**, ya que se enfoca en la cantidad relativa de diferencias entre ellos, en lugar de su magnitud.

$$d(\mathbf{u}, \mathbf{v}) = \frac{\sum_{i=1}^n |u_i - v_i|}{\sum_{i=1}^n (u_i + v_i)}$$

# Resultados: Objetivo específico 2

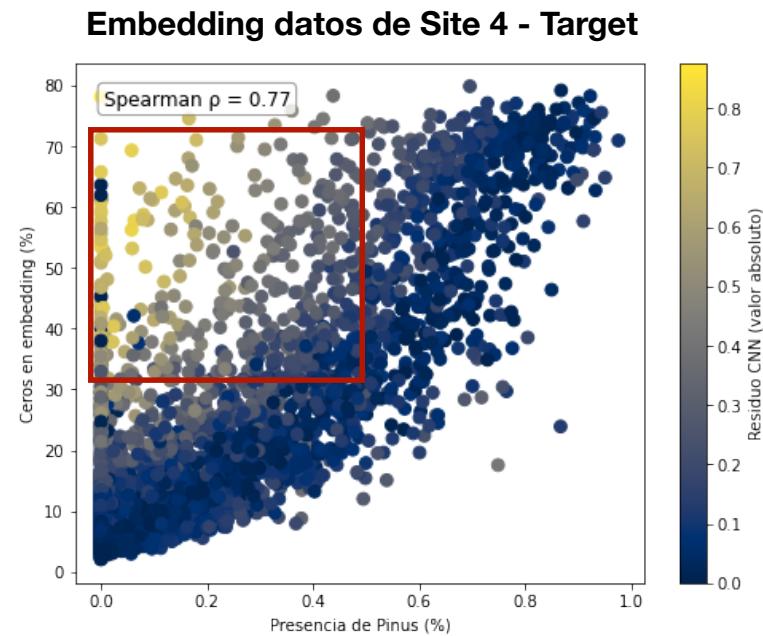
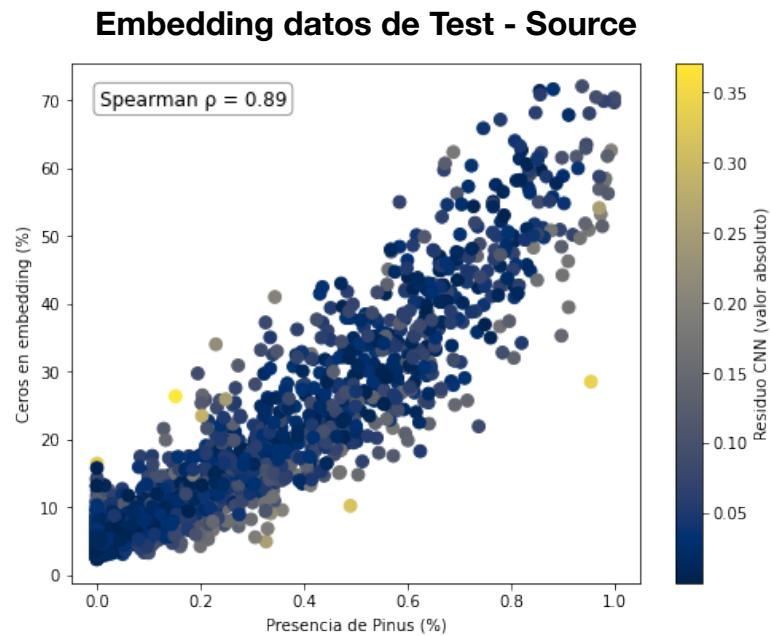
## ¿La cantidad de ceros influye en el error del modelo?



Generar los embeddings para los datos del dominio source y target

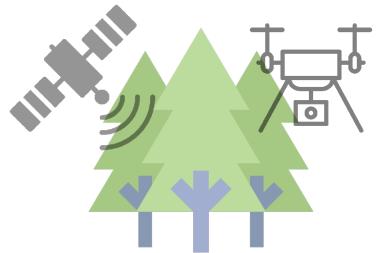
# Resultados: Objetivo específico 2

## Influencia de la cantidad de ceros en el error del modelo



A mayor presencia de pinos en la imagen, mayor es el porcentaje de ceros en los vectores embedding.

# Conclusiones



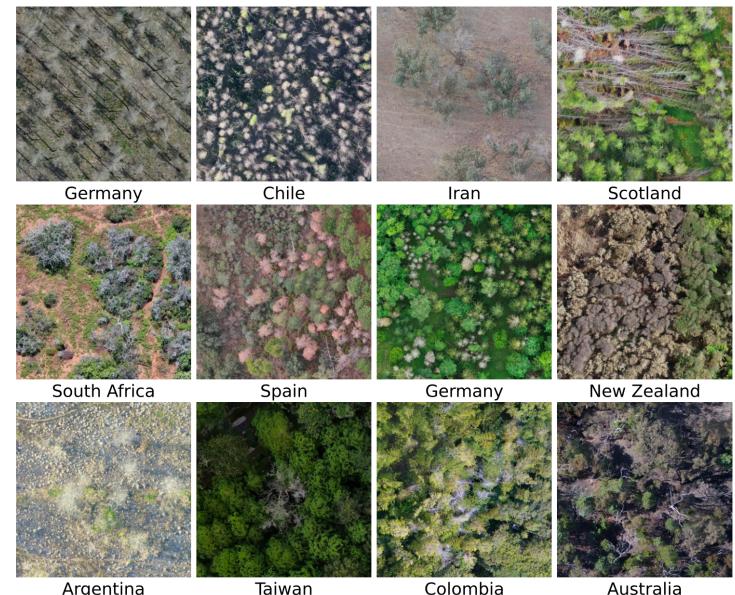
- Las evaluaciones en sitios independientes son esenciales para **evitar estimaciones excesivamente optimistas del desempeño**, ya que los modelos entrenados en un solo sitio tienden a ser sobre-optimistas, mientras que los modelos **multi-sitio muestran un comportamiento más consistente al transferirse** a nuevas áreas geográficas.
- La cuantificación de la **similitud permitirá un mejor utilización** de los modelos actuales, proporcionando una medida preliminar antes de aplicar los modelos a nuevas áreas o adquisiciones.
- La similitud entre **representaciones embedding depende en gran medida de la estructura interna de los vectores**. Por ejemplo, embeddings con una alta proporción de valores en cero pueden resultar más sensibles a pequeñas variaciones en dichos valores.

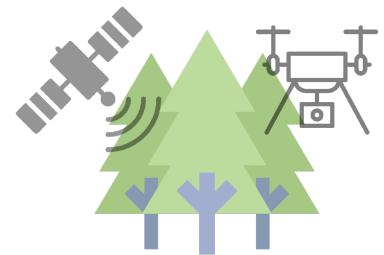
# Trabajo a futuro

- Se está evaluando los patrones encontrados se pueden replicar en **otros tipo de tareas**, por ejemplo en modelos de **clasificación y segmentación**.
- Actualmente estamos trabajando en un nuevo problema enfocado en la **detección de árboles muertos**.
- En una tercera línea de trabajo, se propone **incorporar técnicas de adaptación de dominio**, las cuales podrían reducir las discrepancias entre conjuntos de datos y mejorar la transferencia hacia nuevos dominios.

**deadtrees.earth**

An open database for accessing, contributing, analyzing, and visualizing remote sensing-based tree mortality data.





# Gracias por su atención

**¿Pueden los modelos basados en arquitecturas de deep learning aplicarse en nuevas regiones geográficas?: una perspectiva desde teledetección**